

Project CHU - Cloud Healthcare Unit

CESI
ÉCOLE D'INGÉNIEURS

Diego BESSIS, Matteo Turc
Lucas Crouzet, Theo Sutra



CONTEXTE & PROBLEMATIQUE

Livrer en 3 semaines une maquette Big Data CHU exploitant l'environnement Hadoop/Cloudera existant créé par Archie (stagiaire)

- Comprendre et valider architecture Big Data distribuée
- Respect RGPD données santé | Performance + Scalabilité



ARCHITECTURE & BIG DATA

COUCHE 1 : SOURCE DE DONNEES

- CSV, Excel (données patients structurées)
- 2 Bases PostgreSQL (systèmes hospitaliers existants)
- Collecte multi-sources hétérogènes

COUCHE 2: STOCKAGE DISTRIBUÉ

- Format Parquet : columnar, compressé, optimisé analytique
- Partitionnement : par année et région
- Avantages : Rapide, réduction stockage
- Stockage : données brutes non transformées

COUCHE 3: ETL - TRAITEMENT

- Airflow : orchestration et planification des pipelines
- Python : développement des transformations
- PyArrow : export optimisé vers Parquet
- Traitements : nettoyage, transformation, RGPD

COUCHE 4: PLATEFORME BIGDATA

- DuckDB : base analytique en mémoire (perf)
- DBT : orchestration des transformations SQL
- Lecture directe : Parquet sans chargement
- Modèle en étoile : dimensions + faits
- Agrégations complexes : pré-calculs optimisés

COUCHE 5: ENTREPOSAGE

- PostgreSQL : tables finales uniquement
- Dimensions : Patient, Temps, Service, Pathologie
- Faits : données pré-agrégées
- Optimisations : index, agrégats, partitionnement temporel
- Modèle étoile : requêtes analytiques optimisées

COUCHE 6: VISUALISATION

- Power BI (dashboards interactifs)
- RLS (Row Level Security par service)
- 8 indicateurs métier temps réel



CONFORMITÉ RGPD & SÉCURITÉ

Pseudonymisation SHA-256 (identifiants patients)
Chiffrement AES-256 (stockage) + TLS (réseau)
Minimisation données | Conservation 5 ans | Archivage automatique
DPIA validée | Conformité HDS + ISO 27001
RLS Power BI (accès par profil médical)
Logs audit complets | Hébergement zone EU



Modèle dimensionnel - Schéma étoile

Table de faits : Hospitalisations (durée, coût, nb actes, taux de réussite)

Dimensions :

- Patient (âge, genre, région – anonymisé)
- Temps (jour, mois, année)
- Service (département, spécialité)
- Pathologie (code CIM-10, gravité)

Optimisations : partitionnement temporel, index bitmap, agrégats pré-calculés



MÉTHODOLOGIE - SPRINT 3 SEMAINES

J1-2 : Audit infrastructure → Audit sources
→ Validation Data Lake Parquet + Airflow
J3-4 : Conception modèle → Schéma étoile
→ Validation besoins CHU
J5-8 : ETL + Anonymisation → DAGs Airflow + Python/PyArrow
→ Anonymisation RGPD
J9-12 : Transformations + Data Mart → DuckDB + DBT
→ Chargement PostgreSQL
J13-15 : Dashboards + Tests → Power BI
→ Tests + Documentation
J17 : Recette finale → Validation comité projet

SOURCE

CNIL – Données de santé & RGPD
Databricks – Medallion Architecture
Kimball Group – Data Warehouse Design
Microsoft – Power BI Security (RLS)
Big Data Analytics with Hadoop 3 – Sridhar Alla (Packt, 2019)