

Project CHU - Cloud Healthcare Unit

CESI
ÉCOLE D'INGÉNIEURS

Diego BESSIS, Matteo Turc
Lucas Crouzet, Theo Sutra



CONTEXTE & PROBLEMATIQUE

Livrer en 3 semaines une maquette Big Data CHU exploitant l'environnement Hadoop/Cloudera existant créé par Archie (stagiaire)

- Comprendre et valider architecture Big Data distribuée
- Respect RGPD données santé | Performance + Scalabilité



ARCHITECTURE & BIG DATA

COUCHE 1 : SOURCE DE DONNEES

- CSV, Excel (données patients structurées)
- 2 Bases PostgreSQL (systèmes hospitaliers existants)
- Collecte multi-sources hétérogènes

COUCHE 2: STOCKAGE DISTRIBUÉ

- HDFS Hadoop (cœur du système)
- Cluster 5 nœuds | Réplication x3 (tolérance pannes)
- Format Parquet optimisé colonnes
- Capacité 15TB extensible

COUCHE 3: ETL - TRAITEMENT

- Spark MapReduce (parallélisation traitements)
- Map: lecture parallèle | Reduce: agrégations
- Nettoyage + Transformation + Anonymisation RGPD

COUCHE 4: PLATEFORME BIGDATA

- Cloudera Hadoop (distribution entreprise)
- Hive: Requêtes SQL sur données HDFS
- Analyse de données distribuée
- Virtualisation infrastructure (VMware)

COUCHE 5: ENTREPOSAGE

- Base de données relationnelle (PostgreSQL)
- Modèle dimensionnel (schéma étoile)
- Cube OLAP multidimensionnel (requêtes)
- Optimisations: index, agrégats pré-calculés

COUCHE 6: VISUALISATION

- Power BI (dashboards interactifs)
- RLS (Row Level Security par service)
- 8 indicateurs métier temps réel



CONFORMITÉ RGPD & SÉCURITÉ

Pseudonymisation SHA-256 (identifiants patients)
Chiffrement AES-256 (stockage) + TLS (réseau)
Minimisation données | Conservation 5 ans | Archivage automatique
DPIA validée | Conformité HDS + ISO 27001
RLS Power BI (accès par profil médical)
Logs audit complets | Hébergement zone EU



Modèle dimensionnel - Schéma étoile

Table de faits : Hospitalisations (durée, coût, nb actes, taux de réussite)

Dimensions :

- Patient (âge, genre, région – anonymisé)
- Temps (jour, mois, année)
- Service (département, spécialité)
- Pathologie (code CIM-10, gravité)

Optimisations : partitionnement temporel, index bitmap, agrégats pré-calculés



MÉTHODOLOGIE - SPRINT 3 SEMAINES

J1-2: Audit architecture Archie (Cloudera/Hadoop) + Validation infra
J3-4: Conception modèle dimensionnel (étoile) + Validation besoins CHU
J5-8: Développement ETL Spark + Anonymisation RGPD
J9-12: Chargement Data Mart + Création cube OLAP + Index
J13-16: Dashboards Power BI (8 indicateurs) + Tests + Documentation
J17: Recette finale + Validation comité projet

SOURCE

CNIL – Données de santé & RGPD
Databricks – Medallion Architecture
Kimball Group – Data Warehouse Design
Microsoft – Power BI Security (RLS)
Big Data Analytics with Hadoop 3 – Sridhar Alla (Packt, 2019)